

客製化FAQ 問答集客服機器人

RAG SaaS — AI 智慧客服平台

專案概述

這是一套以 **Retrieval-Augmented Generation (RAG)** 為核心的多租戶 SaaS 平台，讓任何商家只需上傳自己的文件或 FAQ，即可在幾分鐘內擁有一個能理解品牌知識、用品牌語氣回答顧客問題的 AI 客服機器人，並以嵌入式元件的形式直接掛載到商家自己的網站上。

技術架構

層級	技術選型
後端	FastAPI (Python 3.11+)、async/await 全鏈路非同步
前端	Next.js 16.2.4、React 19、shadcn/ui、Tailwind CSS 4
向量資料庫	Qdrant (自建部署)
關聯式資料庫	PostgreSQL 16
LLM & Embedding	Google Vertex AI — Gemini 2.5 Flash (生成) + text-embedding-004 (向量化, 768 維)
身份驗證	Firebase Auth (商家帳號 email/password; 終端用戶 anonymous auth)
文件儲存	Google Cloud Storage
容器化	Docker Compose 一鍵啟動所有基礎設施服務

核心亮點功能

1. 自建專屬知識庫，完全掌控問答範疇

商家可透過後台上傳多種格式(pdf、excel、txt...)的說明文件、FAQ、產品規格等，系統會自動完成解析 → 分塊 → 向量化 → 雙軌索引(PostgreSQL + Qdrant)的完整 Ingestion Pipeline，無需任何技術背景即可操作。每個租戶的向量資料嚴格以 `tenant_id` 隔離，多租戶間零資料洩漏風險。

2. 品牌化語氣客製設定

商家可在後台自訂 AI 的回答語氣(正式 / 親切 / 專業 / 活潑)、歡迎詞、拒答時的替代訊息等，所有個性化設定以 JSON 格式儲存於租戶設定欄位，即時生效無需重新部署。讓 AI 客服真正融入品牌形象，而非千篇一律的機器口吻。

3. 多種嵌入方式，無縫整合商家網站

聊天元件支援多種展示模式(側邊欄、懸浮按鈕、全頁嵌入)，商家只需複製一段 script 標籤即可掛載到任何網站，完全不影響原有頁面結構。前端以 Next.js 實作，支援獨立路由 `/chat/[tenantId]` 與可嵌入版本 `/widget/[tenantId]`。

4. 八階段精密 RAG Pipeline，大幅提升回答品質

每一則用戶訊息依序經過：

1. 打招呼偵測 — 識別純問候語，直接回應，不消耗 LLM 額度
2. 每日配額檢查 — 防止超量呼叫，精細區分「超額」vs「真實拒答」
3. 轉接偵測 — 識別用戶主動要求真人，提前退出 RAG 流程
4. **Query Rewrite** — 用 LLM 將口語化問題改寫為語意更清晰的檢索 Query，提升召回率
5. 混合檢索(Hybrid Retrieval) — BM25 關鍵字搜尋 + Qdrant 向量搜尋，透過 **Reciprocal Rank Fusion(RRF)** 融合兩路結果，兼顧精確匹配與語意理解
6. 重排序(Reranking) — 對 Top-K 候選文段二次精排，確保最相關內容優先進入 Context
7. 可答性判斷(**Answerability Check**) — 若所有文段均與問題無關，主動拒答並記錄，避免幻覺(Hallucination)
8. **LLM 生成** — 以 Gemini 2.5 Flash(temperature=0.1)生成有引用來源的最終答案

5. 未解問題自動收集，形成知識庫閉環

當 AI 判斷問題超出知識範疇而拒答時，系統自動將該問題寫入 `UnansweredQuestion` 資料表(自動去重)，商家可在後台「未解問題」列表中一覽所有真實顧客問過卻答不出的問題，有的放矢地補充文件、持續優化知識庫。這讓知識庫從靜態文件變成能隨業務演進的活知識系統。

6. 真人轉接機制，杜絕用戶與 AI 鬼打牆

聊天介面提供「聯絡真人客服」按鈕，當用戶遇到 AI 無法解決的問題時，可主動發起轉接請求，且系統保證此類轉接不會被誤計為拒答次數，保持分析數據的精準度。

7. AI 自動摘要，轉接真人時消除重複自我介紹

這是本專案最具差異化的亮點之一：用戶點擊轉接真人後，系統會呼叫 LLM 自動生成一份結構化對話摘要(問題描述、已嘗試方案、期望結果等)，用戶可在送出前自行編輯確認，再提交給商家後台。真人客服接手時，對話脈絡一目了然，用戶不需要重新從頭解釋問題，大幅改善服務體驗。後台支援完整工單狀態追蹤：`new → read → resolved`。

8. 精細化數據分析儀表板

後台提供多維度數據洞察：

- 今日拒答次數 — 僅計算真實知識缺口導致的拒答(排除轉接、超額等系統事件)，精準反映知識庫覆蓋率
- 累計未解問題清單 — 去重後的真實用戶痛點列表
- 轉接紀錄 — 完整的真人客服請求歷史，含 AI 生成摘要

- 對話信心分數(**confidence_score**) — 每則回答帶有可信度標記, 供商家識別灰色地帶回答

9. 多租戶架構, 資料嚴格隔離

系統以 Firebase UID 作為租戶根身份, 所有資料庫模型(Document、Conversation、Message、UnansweredQuestion、HandoffRequest)均透過外鍵關聯至 Tenant 表; Qdrant 向量查詢強制帶入 `tenant_id` payload filter, 即便共用同一向量資料庫實例, 也絕不會出現跨租戶資料混用。

10. Playground 沙盒測試環境

商家可在後台直接以「測試模式」對話, 驗證知識庫更新效果, 且測試對話(`is_playground=True`)與真實用戶對話在資料庫層分離, 不污染分析數據。

系統設計亮點

- 全非同步架構: FastAPI + asyncpg + 背景 Indexing Task, 高併發下不阻塞
- 語意分析精準度: 768 維 text-embedding-004 + BM25 雙路混合檢索, 搭配 RRF 融合, 比單一向量搜尋召回率更高
- **Hallucination** 防護: 可答性判斷層 (Answerability Check) 確保 AI 寧可說「不知道」也不亂答
- **LLM** 成本控管: 打招呼偵測短路 + 每日 Token 額度上限 (可按租戶個別設定), 確保平台可持續運作
- 引用來源透明度: 每則回答帶有文件引用 (citations), 用戶可追溯答案出處, 建立信任感

適用場景

電商客服、SaaS 產品說明、醫療診所預約問答、金融產品諮詢、政府機關常見問題——任何有固定知識範疇且需要 24 小時即時回應的場景, 皆可用本平台在無需工程師介入的情況下快速部署專屬 AI 客服。